

TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN


PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

AMES HOUSING

Khảo sát bài toán • Phân tích đơn biến • Phân tích đa biến
Giá trị thiếu • Mẫu bất thường • Ngoại lệ

EDA

Ames Housing



1. Khảo sát bài toán

Bối cảnh, dữ liệu và mục tiêu của EDA

Bài toán

Dự đoán giá bán nhà (SalePrice) dựa trên các đặc điểm của ngôi nhà. Đây là bài toán hồi quy và EDA là bước trước khi xây dựng mô hình.

Nguồn dữ liệu

Ames Housing được De Cock (2011) giới thiệu. Nhóm sử dụng phiên bản Kaggle “House Prices - Advanced Regression Techniques”.

Phạm vi thực hiện

Tập trung vào hiểu dữ liệu, xem phân phối, tìm mối quan hệ giữa biến và SalePrice, kiểm tra giá trị thiếu và phát hiện quan sát bất thường.

1460

quan sát train

81

cột

79

biến đầu vào

1

biến mục tiêu

2006-2010

giai đoạn dữ liệu

Ý chính cần nhớ

EDA giúp nhóm biết dữ liệu đang có đặc điểm gì, có vấn đề gì và những biến nào đáng chú ý trước khi chuyển sang bước mô hình hóa.

2. Tổng quan dữ liệu

Nhìn dữ liệu theo kiểu lưu trữ và theo ý nghĩa

38 biến numeric


Gồm diện tích, số lượng, giá bán và một số biến lưu dạng số nhưng có bản chất thứ bậc hoặc mã nhóm.

43 biến categorical

Mô tả vị trí, kiểu nhà, vật liệu, chất lượng và các đặc điểm theo nhóm.

Không có bản ghi trùng

Kiểm tra toàn bộ dòng và cột Id đều không phát hiện trùng. Id chủ yếu dùng để nhận diện quan sát.



Ví dụ cần phân biệt

OverallQual


MSSubClass

Đều được Python đọc là số, nhưng cần xem theo ý nghĩa:

OverallQual là mức chất lượng theo thang điểm, còn MSSubClass là mã phân loại.

3. Phân tích đơn biến: SalePrice

Xem phân phối và độ lệch của biến mục tiêu



Kết quả chính

- Min: 34.900 USD
- Max: 755.000 USD
- Trung bình: khoảng 180.921 USD
- Trung vị: 163.000 USD
- Skewness = 1,88 (sau log: 0,12)


Nhận xét

SalePrice lệch phải khá rõ. Phần lớn nhà tập trung ở mức giá thấp và trung bình, trong khi một số căn có giá cao làm phần đuôi bên phải kéo dài.

Vì vậy, log-transform là một hướng xử lý có thể cân nhắc ở bước mô hình hóa để phân phối cân đối hơn.

4. Phân tích đơn biến: các biến chính

Nhìn nhanh các biến diện tích và biến phân loại



Quan sát nổi bật

- GrLivArea, TotalBsmtSF, 1stFlrSF, LotArea: lệch phải.
- OverallQual tập trung chủ yếu ở mức 5-7.
- NAMES, CollgCr, OldTown có nhiều giao dịch.
- Nhà 1 tầng và 2 tầng chiếm phần lớn.

Histogram

Phù hợp để nhìn dữ liệu tập trung ở đâu và có bị lệch hay không.

Countplot


Cho biết nhóm phân loại nào xuất hiện nhiều hay ít.

Ý nghĩa

Giúp có cái nhìn ban đầu trước khi phân tích mối quan hệ giữa các biến.

5. Phân tích đa biến: tương quan

Các biến số có tương quan khá mạnh với SalePrice



OverallQual $r \approx 0,79$

GrLivArea $r \approx 0,71$

GarageCars / GarageArea $r \approx 0,62 - 0,64$


TotalBsmtSF / 1stFlrSF $r \approx 0,61$

Cách đọc

Hệ số tương quan giúp nhóm xác định những biến đáng chú ý về mặt quan hệ tuyến tính. Đây là kết quả EDA để tham khảo, không phải bằng chứng về nhân quả hay độ quan trọng cuối cùng trong mô hình.

6. Mối quan hệ giữa diện tích, chất lượng và vị trí

Kết hợp scatterplot và boxplot để đọc dữ liệu



GrLivArea và SalePrice

Giá bán tăng theo diện tích nhưng không hoàn toàn tuyến tính. Khi tô màu theo OverallQual (notebook đa biến), nhà chất lượng cao thường có giá cao hơn.




Neighborhood và SalePrice

Giá trung vị khác nhau khá rõ giữa các khu vực. NridgHt và Somerst cao hơn trong nhóm được chọn; OldTown và Edwards thấp hơn đáng kể.

7. Giá trị thiếu

Không phải NaN nào cũng là lỗi dữ liệu



19 / 81 cột có giá trị thiếu

Thiếu nhiều nhất

PoolQC 99,5%
MiscFeature 96,3%
Alley 93,8%
Fence 80,8%
MasVnrType 59,7%

Nhận xét

Theo mô tả dữ liệu, nhiều NaN có thể mang nghĩa “không có đặc điểm đó”, ví dụ không có hồ bơi hoặc hàng rào. Vì vậy cần xử lý theo từng biến, không nên điền thiếu một cách máy móc.

LotFrontage thiếu khoảng 17,7%: có thể cân nhắc điền trung vị theo Neighborhood để phù hợp hơn với từng khu vực.


8. Mẫu bất thường và ngoại lệ

Kết hợp IQR với kiểm tra trực quan và đối chiếu paper

IQR

LotArea có 4,73% và SalePrice có 4,18% điểm nằm ngoài ngưỡng IQR. Nhưng điểm ngoài IQR chưa chắc là dữ liệu sai.

Với dữ liệu nhà ở, căn nhà rất lớn hoặc rất đắt vẫn có thể là giao dịch thật.



2 mẫu nổi bật trong train Kaggle

Id 524
Id 1299

Cả hai có GrLivArea > 4000 sqft và giá bán thấp bất thường so với xu hướng chung.

Paper De Cock đề cập 5 quan sát > 4000 sqft trong bộ Ames đầy đủ. Tập train Kaggle của nhóm chỉ có 2 quan sát nổi bật này.

9. Kết luận EDA

Những điểm cần nhớ trước khi xây dựng mô hình

01

Bài toán

Hồi quy dự đoán SalePrice trên 1460 quan sát train.

02

Phân phối

SalePrice và nhiều biến diện tích lệch phải; log-transform là hướng có thể cân nhắc.

03

Quan hệ đáng chú ý

OverallQual, GrLivArea, GarageCars/GarageArea và TotalBsmtSF có tương quan khá mạnh với SalePrice.

04

Dữ liệu chất lượng

19 cột có giá trị thiếu; nhiều trường hợp là missing có cấu trúc và cần xử lý theo ý nghĩa biến.

05

Ngoại lệ

2 bản ghi nổi bật trong train Kaggle cần kiểm tra riêng trước khi mô hình hóa.
